GraphRAG e KAG sobre um Catálogo de Filmes e Séries: Recuperação em Grafo de Propriedades para Reduzir Alucinações em LLMs

Ewellyn Maria[1], **Gustavo Palmeira**[1], **Rafael Cirne**[1], **Julliane Di Paula**[1], **Felipe Souto Maior**[1], **Arthur Xavier**[1]

[1]UNIPÊ – Centro Universitário de João Pessoa
BR-230 – Água Fria, João Pessoa – PB, 58053-000

{ewellyn.andrade, gustavo.martinez, rafael.medeiros, julliane.xavier, felipe.mendes, acavalcante}@cs.unipe.edu.br

Abstract. *Large language models answer fluently even when they lack the facts, which produces hallucinations. This paper presents a GraphRAG/KAG prototype that stores a catalog of movies and TV series in a Neo4j property graph and answers multi-hop questions from retrieved, traceable evidence. We compare three variants—an LLM without retrieval, vector RAG and hybrid GraphRAG—on 17 questions whose gold answers are derived from the catalog itself, including questions that the catalog cannot answer. [TODO: resumir resultado numérico após a execução final.]*

Resumo. *Modelos de linguagem respondem com fluência mesmo sem conhecer os fatos, o que gera alucinações. Este trabalho apresenta um protótipo de GraphRAG/KAG que armazena um catálogo de filmes e séries em um grafo de propriedades no Neo4j e responde perguntas multi-hop a partir de evidências recuperadas e rastreáveis. Comparamos três variantes (LLM sem recuperação, RAG vetorial e GraphRAG híbrido) em 17 perguntas cujo gabarito é derivado do próprio catálogo, incluindo perguntas que o catálogo não consegue responder. [TODO: resumir o resultado numérico após a execução final.]*

1. Introdução

Modelos de linguagem de grande porte (LLMs) geram texto plausível independentemente de possuírem a informação necessária, e esse comportamento é conhecido como alucinação [Ji et al. 2023]. A geração aumentada por recuperação (RAG) reduz o problema ao fornecer ao modelo trechos de texto relevantes [Lewis et al. 2020], mas a busca por similaridade vetorial recupera trechos isolados e tem dificuldade com perguntas que exigem combinar fatos espalhados em vários documentos, como *"quais atores atuaram em séries criadas por quem criou Better Call Saul?"*.

Abordagens baseadas em grafos de conhecimento atacam essa limitação ao representar entidades e relações explicitamente, permitindo percorrer múltiplos saltos [Edge et al. 2024, Liang et al. 2024]. Este trabalho constrói um protótipo acadêmico de ponta a ponta e responde à pergunta de pesquisa: **a recuperação em grafo reduz a alucinação de um LLM em relação ao mesmo LLM sem recuperação e ao RAG puramente vetorial?**

As contribuições são: (i) um pipeline Text-to-Graph sobre um catálogo de filmes e séries com persistência em Neo4j; (ii) recuperação híbrida (vetor, texto completo e caminho no grafo) com resposta fundamentada e Cypher exibido; e (iii) um protocolo de avaliação cujo gabarito é derivado do catálogo e que inclui perguntas sem resposta, para medir se o sistema se abstém em vez de inventar.

2. Fundamentação Teórica

2.1. Alucinação e RAG

Alucinação é a geração de conteúdo não sustentado pela fonte ou pelo mundo [Ji et al. 2023]. Em sistemas RAG [Lewis et al. 2020], a fonte é o conjunto de trechos recuperados, e a fidelidade a ela (*grounding*) é a propriedade que buscamos medir.

2.2. Grafos de propriedades e Cypher

Em um grafo de propriedades rotulado (LPG), nós e relações possuem rótulos e propriedades. O Neo4j armazena esse modelo e é consultado com Cypher [Francis et al. 2018]. Perguntas multi-hop correspondem a padrões de caminho, por exemplo $(Person) - [: ACTED_IN] \rightarrow (Movie) \leftarrow [: DIRECTED] - (Person)$.

2.3. GraphRAG e KAG

O GraphRAG [Edge et al. 2024] constrói um grafo a partir de texto e usa detecção de comunidades e resumos para responder perguntas globais; o KAG [Liang et al. 2024] integra grafo de conhecimento e geração com raciocínio guiado por lógica. Algoritmos como PageRank [Page et al. 1999] e Leiden [Traag et al. 2019] podem enriquecer o contexto com a importância e a comunidade dos nós.

3. Arquitetura do Sistema

O fluxo implementado é: fonte → documento → chunk → entidades e relações → Neo4j → recuperação híbrida → contexto fundamentado → interface.

- **Dados:** catálogo de 9 títulos (5 filmes e 4 séries) com diretores/criadores, elenco, gêneros e estúdio, conferidos na Wikipedia (CC BY-SA 4.0).
- **Text-to-Graph:** nós `Movie`, `Series`, `Person`, `Genre`, `Studio`, `Document`, `Chunk` e `Entity`; relações `DIRECTED`, `CREATED`, `ACTED_IN`, `HAS_GENRE`, `PRODUCED_BY`, `HAS_CHUNK`, `MENTIONS` e `RELATED_TO`.
- **Recuperação:** índice vetorial (cosseno, 384 dimensões), índice de texto completo e pontuação por caminho mais curto, combinados em um escore híbrido.
- **Geração:** LLM local (Ollama) com as evidências como único contexto; sem Ollama, resposta por *template*.

4. Metodologia de Avaliação

4.1. Conjunto de perguntas

São 17 perguntas em cinco categorias: 1 salto (3), 2 saltos (6), 3 saltos (2), agregação (1) e *sem resposta no catálogo* (4). O gabarito de cada pergunta (entidades esperadas e documentos de suporte) é **calculado a partir de `titles.json`**, e não escrito à mão, o

que evita inconsistência e permite regerar o conjunto se o catálogo crescer. As perguntas sem resposta (por exemplo, um filme que não está no catálogo) verificam se o sistema admite não saber; a geração do conjunto falha se o catálogo passar a conter a resposta, para que essas perguntas continuem válidas.

4.2. Variantes comparadas

1. **LLM sem recuperação:** o mesmo modelo recebe apenas a pergunta, com prompt neutro.
2. **RAG vetorial:** os 5 documentos mais próximos pelo índice vetorial viram contexto.
3. **GraphRAG híbrido:** contexto da recuperação híbrida com caminho no grafo.
4. **LLM externo sem recuperação** (opcional): respostas fornecidas por arquivo.

O modelo gerador e o prompt de fundamentação são idênticos nas variantes 2 e 3; apenas o contexto muda.

4.3. Métricas

- **Recall de entidades:** fração das entidades do gabarito citadas na resposta.
- **Acerto:** perguntas respondíveis com recall total; perguntas sem resposta com abstenção e sem entidades inventadas.
- **Alucinação:** resposta que cita nome próprio ausente do catálogo e da pergunta, ou que responde com segurança uma pergunta sem resposta no catálogo.
- **Avaliação humana:** correção, relevância, completude e fundamentação (escala 1–5) em planilha-modelo, para validar a métrica automática.

A alucinação é medida em relação ao *catálogo*, não ao mundo real: uma resposta verdadeira fora do catálogo conta como não fundamentada. A detecção de entidades é heurística (nomes próprios com inicial maiúscula) e subestima casos em que uma palavra única inicia a frase.

5. Resultados

Tabela 1. Resultados gerais (preencher após a execução final).

Variante	Acerto	Recall médio	Alucinação	Abstenção correta
LLM sem recuperação	–	–	–	–
RAG vetorial	–	–	–	–
GraphRAG híbrido	–	–	–	–

6. Discussão e Limitações

Os resultados devem ser lidos com cautela. O catálogo tem apenas 9 títulos, de modo que o experimento demonstra o mecanismo, mas não permite conclusões estatísticas. Os embeddings usados são por *hashing* determinístico e não capturam semântica, o que favorece a busca por termos exatos. O gerador é um modelo pequeno executado localmente, e a métrica automática depende de heurística de extração de entidades. Por fim, o baseline sem recuperação tem vantagem injusta de conhecimento paramétrico sobre os filmes reais, mas é penalizado por usar fatos fora do catálogo.

7. Conclusão

Referências

Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., e Larson, J. (2024). From local to global: A graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*.

Francis, N., Green, A., Guagliardo, P., Libkin, L., Lindaaker, T., Marsault, V., Plantikow, S., Rydberg, M., Selmer, P., e Taylor, A. (2018). Cypher: An evolving query language for property graphs. In *Proceedings of the International Conference on Management of Data (SIGMOD)*, pages 1433–1445.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., e Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., tau Yih, W., Rocktäschel, T., Riedel, S., e Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33.

Liang, L., Sun, M., Gui, Z., Zhu, Z., Jiang, Z., Zhong, L., Qu, Y., Zhao, P., Bo, Z., Yang, J., Xiong, H., Yuan, L., Xu, J., Wang, Z., Zhang, Z., Zhang, W., Chen, H., Chen, W., e Zhou, J. (2024). KAG: Boosting LLMs in professional domains via knowledge augmented generation. *arXiv preprint arXiv:2409.13731*.

Page, L., Brin, S., Motwani, R., e Winograd, T. (1999). The PageRank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab.

Traag, V. A., Waltman, L., e van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9:5233.